

Biases and Responsible Datasets

DeepDive for AI and Computer Vision WS25/26

Jennifer Janac, Joel Schoemaker-Ramos

'Urgent clarity' sought over racial bias in UK police facial recognition technology

Testing showing racial bias against black and Asian people prompts watchdog to ask Home Office for explanation



Latest • 11 April 2025

AI giants are stealing our creative work




LEADERSHIP > LEADERSHIP STRATEGIES

The AI Recruitment Takeover: Redefining Hiring In The Digital Age

By [Keith Ferrazzi](#), Contributor. © I cover the future of work, team effectiveness...

Published Mar 27, 2025 at 05:33pm EDT

Original image
(my work)



AI-generated,
based on my work



Bias and Fairness

Aiming at AI systems that are more fair and just.

01

(unerwünschte) Bias

**Systematische Verzerrungen
sind in den Daten kodiert (z. B.
durch Scheinkorrelationen,
kausale Zusammenhänge
zwischen den Variablen und
nicht repräsentative
Datenstichproben)**

**Der Einsatz von CV-Systemen
ohne umfassende ethische
Bewertung kann zu
erheblicher Diskriminierung
von Minderheiten und
geschützten Gruppen führen**

Unfairness

Unfairness ist eine Konsequenz von Bias sein

Neuronale Modelle neigen dazu, Korrelationen zu erfassen, was zu voreingenommenen Lösungen führen kann

Fairness

Abwesenheit jeglicher Voreingenommenheit oder Bevorzugung gegenüber einem Individuum oder einer Gruppe basierend auf deren angeborenen oder erworbenen Eigenschaften





5min

Gedankenanstöße zu Fairness

**Wer entscheidet was
Fair ist?**

**Wie misst man
Fairness?**

Gedankenanstöße zu Fairness

**Wer entscheidet was
Fair ist?**

Mathematisch unmöglich alle fairness definitionen gleichermaßen umzusetzen
Richtlinien (EI AI Act)
Forscher und Experten: erstellen empirische fairness Metriken
Gesellschaft entscheidet welche Merkmale sensibel gelten

**Wie misst man
Fairness?**

Gruppen Fairness: Gruppen sollen im Durchschnitt gleich behandelt oder ähnliche Ergebnisse bekommen.

Individuelle Fairness: Individuen, die in Bezug auf eine bestimmte Aufgabe ähnlich sind, ähnlich behandelt werden sollten, unabhängig davon, welcher demografischen Gruppe sie angehören

Metriken für Fairness

Gruppenfairness	Demografische Parität	die Wahrscheinlichkeit eines Ergebnisses für eine Person innerhalb oder außerhalb der geschützten Gruppe soll gleich sein
	Chancengleichheit	(True-Positiv-Rate (TRP)): misst, ob qualifizierte Personen, unabhängig von ihrer Gruppenzugehörigkeit gleich behandelt werden, indem sie die Wahrscheinlichkeit betrachtet, dass sie ein positives Ergebnis erhalten
	Gesamtgenauigkeit	Die Genauigkeit des Modells sollte für verschiedene Gruppen gleich sein
individuelle	Fairness durch Unbewusstsein	entfernt alle Informationen zur Gruppenzugehörigkeit (weil Geschlecht, Ethnie, Alter) aus dem Datensatz

Quellen von Bias

Wo entsteht Bias?

02

Menschliche Ursachen

Explizites Bias

conscious and intentional prejudices or beliefs about certain groups of people


Implizites Bias

Unconscious and shaped by social conditioning, media representation, and cultural exposure

“While we may view explicit bias as ethically incorrect, our brains automatically establish implicit associations”

(Chapman)

Bias im CV-Datenlebenszyklus




Selection Bias

Datensatz enthält fast nur Gesichter weißer Menschen



Gemischte Realität → einseitiger Datensatz



Framing Bias



Person ganz im Bild



Person beim Joggen –
Ganze Figur



Person halb
abgeschnitten




Nahaufnahme eines
dicken Bauchs – Kopf
abgeschnitten

Label Bias

Label im Datensatz:
„neutral“



Label im Datensatz:
„sad“





5min

Label Studio Playground

<https://labelstud.io/playground/>

Image Annotation Techniques

1 Bounding Box



2 Landmarking



3 Masking



4 Polygon



5 Polyline



6 Tracking



7 Transcription



Label Studio Playground

```
1 <View>
2 <Image names="image" value="$image"/>
3 <RectangleLabels name="label" tagName="image">
4 <Label value="Airplane" background="green"/>
5 <Label value="Car" background="blue"/>
6 </RectangleLabels>
7 </View>
```



Airplane 1 Car 2

Bias-Detektion

Wie erkennt man Verzerrungen?

There is no such thing as a bias-free dataset

03

Qualitative Datenanalyse nach BSI

Wie repräsentativ sind die Daten?

Wann wurden die Daten erhoben?

Wie wurden die Daten erhoben?

Wie aufwändig ist die Datenerhebung?

Falls Daten von Menschen erhoben werden, wissen diese von der Datenerhebung?

Wer hat die Möglichkeit, an der Datenerhebung teilzuhaben?

Wie ist die (zeitliche, räumliche, etc.) Auflösung der Daten?

Welche Merkmale der Daten wurden tatsächlich gemessen und welche lediglich ab- oder hergeleitet?

Wurden alle relevanten Merkmale der Daten erfasst?

Können die Daten Falschinformationen enthalten?

**Bias verstehbar
machen**

Quantitative Datenanalyse nach BSI

Schiefe der Verteilung

Starke Schiefe = eine Gruppe dominiert, andere sind selten/fehlen.

Korrelationen

Besonders kritisch: Merkmale, die mit sensiblen Attributen korrelieren (Ethnizität, Geschlecht ...).

Autokorrelation (Zeitreihen)

Nur für Daten mit Zeitbezug (Video), Ähneln sich aufeinanderfolgende Werte stark?

Varianz von Merkmalen

zu geringe Varianz weist auf irrelevante oder verzerrende Features hin


Vergleich von Subpopulationen (z.B. mit ANOVA)

prüft statistisch, ob Gruppen ungleich behandelt/abgebildet sind


**Bias messbar
machen**

Fallbeispiel: Autonomous Driving

Annotationstool



Demografische Inventur/ Schiefe der Verteilung



Open Source Datasets for Computer Vision

FairFace

- Ausgewogener Gesichtsdatensatz (Alter, Gender, „Race“/Ethnicity)
- Frei verfügbar
- Zweck: explizit für Fairness & Bias-Analysen entworfen
- <https://github.com/joojs/fairface>

COCO – Common Objects in Context

- großer Standard-Benchmark für Objekterkennung & Segmentierung
- 330K Bilder (>200K labeled), 1,5 Mio. Objekte, 80 Kategorien
- viel Kontext in Alltagsszenen
- <https://cocodataset.org/>

Debiasing | Bias Mitigation

Wo und Wie korrigiert man Verzerrungen?

Der Versuch, die Fairness-Metriken durch Modifizierung der Trainingsdatenverteilung, des Lernalgorithmus oder der Vorhersagen zu verbessern.

Debiasing

Pre-Processing

Daten

Datenverteilung vor dem Training anpassen, um unterrepräsentierte Gruppen besser darzustellen oder Verzerrungen in den Datenobjekten zu entfernen.

Transformationen (Data Augmentation), Resampling, Reweighing,

In-Processing

Modell

Verändert, wie das Modell trainiert wird, um Fairness Metriken zu beachten.

Fairness-Beschränkungen, Adversarial Debiasing, Prejudice Remover Regularizer

Post-Processing

Nach Training

Vorhersagen anpassen, nachdem das Modell Trainiert wurde.

Angleichung der Wahrscheinlichkeiten, Klassifizierung der Ablehnungsoption

Toolkits und Libraries für Debiasing (Auswahl)

IBM AI Fairness 360 (AIF360)

- Metriken für Datensätze und Modelle zum Testen auf Verzerrungen
- Algorithmen zur Verringerung von Verzerrungen in Datensätzen und Modellen

Fairlearn (Microsoft)


- Tools zur Bewertung der Fairness von Prädiktoren für Klassifizierung und Regression
 - Tools, die Ungerechtigkeiten bei der Klassifizierung und Regression mindern
-

Regularien


EU AI ACT

05

EU AI ACT



EU AI Act



Regulation vs. Innovation

Menschenzentriert

Bias wird nicht explizit definiert

Brüsseler Effekt: internationale Orientierung an europäischen Normen

Bürokratie/ Regulatorische Hürden

Key Takeaways

Auf einen Blick

06

Key Takeaways

1. Verantwortung

Fairness ist kein Zufall sie entsteht durch unsere Entscheidungen.

2. Entstehung von Bias

Bias entsteht entlang des gesamten Visual Content Life Cycle besonders bei der Datensammlung.

3. Analyse von Bias

Bias sichtbar machen bedeutet qualitative und quantitative Datenanalyse.

4. Umgang mit Bias

Debiasing ist möglich aber immer ein Trade off. Dafür gibt es fertige toolkits und libraries.

5. Regulierung

Der EU AI Act stuft KI-Anwendungen nach Risiko ein und implementiert Regulieren iterativ.



**Vielen Dank für eure
Aufmerksamkeit!**

Fragen?

Quellen

- intersoft consulting services AG. (2024, 20. September). AI Act as a neatly arranged website – Legal Text. AI Act. <https://ai-act-law.eu/>
- Boesch, G. (2025, 15. Mai). Bias Detection in Computer Vision: A Comprehensive guide. viso.ai. <https://viso.ai/computer-vision/bias-detection/>
- BSI veröffentlicht Whitepaper zu Bias in der künstlichen Intelligenz. (n.d.). Bundesamt Für Sicherheit in Der Informationstechnik. https://www.bsi.bund.de/DE/Service-Navi/Presse/Alle-Meldungen-News/Meldungen/Whitepaper_Bias_KI_250724.html
- Chapman University (o.J.). Data Risk Classification. <https://www.chapman.edu/campus-services/information-systems/security/data-risk-classification.aspx>
- Chapman University (o.J.). Bias in AI. *Chapman*. <https://www.chapman.edu/ai/bias-in-ai.aspx>
- Cook, A.(o.D.). AI Fairness. Kaggle. <https://www.kaggle.com/code/alexisbcook/ai-fairness>
- Fabrizzi, S. et al. (2021). A Survey on Bias in Visual Datasets. arXiv (Cornell University). <https://doi.org/10.48550/arxiv.2107.07919>
- Kalich, A., Rashed, A., (2024). Analyzing Fairness of Computer Vision and Natural Language Processing Models. <https://arxiv.org/html/2412.09900v2>
- Marr, B. (2022). The Problem With Biased AIs (and How To Make AI Better). *Forbes*. <https://www.forbes.com/sites/bernardmarr/2022/09/30/the-problem-with-biased-ais-and-how-to-make-ai-better/>
- Holdsworth, J. (o.J). KI-Bias. *IBM* . <https://www.ibm.com/de-de/think/topics/ai-bias>
- Holland, S., Hosny, A., Newman, S., Joseph, J., & Chmielinski, K. (2018). The Dataset Nutrition Label: a framework to drive higher data quality standards. *arXiv* (Cornell University). <https://doi.org/10.48550/arxiv.1805.03677>
- Llorca, D. F., Frau, P., Parra, I., Izquierdo, R. & Gómez, E. (2024). Attribute annotation and bias evaluation in visual datasets for autonomous driving. *Journal Of Big Data*, 11(1). <https://doi.org/10.1186/s40537-024-00976-9>

-
- Metrics for Dataset Demographic Bias: A Case Study on Facial Expression Recognition. (o. D.). <https://arxiv.org/html/2303.15889v2>
- Parraga, O. et al. (2022). Debiasing Methods for fairer Neural Models in vision and Language Research: a survey. Machine Learning Theory and Applications (MALTA) Lab, PUCRS, Brazil. <https://doi.org/10.48550/arxiv.2211.05617>
- Silberg, J., Manyika, J. (2019). Tackling bias in artificial intelligence (and in humans). <https://www.mckinsey.com/featured-insights/artificial-intelligence/tackling-bias-in-artificial-intelligence-and-in-humans>
- Short, L. (2025): Ethics in AI: Why It Matters. Professional & Executive Development. Harvard Division of Continuing Education. <https://professional.dce.harvard.edu/blog/ethics-in-ai-why-it-matters/#The-Importance-of-AI-Ethic>
- Übersicht über das KI-Gesetz | EU-Gesetz über künstliche Intelligenz. (o. D.). <https://artificialintelligenceact.eu/de/high-level-summary/>
- Wachter, S. & Oxford Internet Institute, University of Oxford. (2024). Limitations and Loopholes in the EU AI Act and AI Liability Directives: What This Means for the European Union, the United States, and Beyond. In Yale Journal of Law & Technology, Yale Journal Of Law & Technology (Bd. 26, Nummer 3, S. 672–718). https://yjolt.org/sites/default/files/wachter_26yalejltech671.pdf
- Zeitplan für die Umsetzung | EU-Gesetz über künstliche Intelligenz. (o. D.). <https://artificialintelligenceact.eu/de/implementation-timeline/>

Dokumentation: Wie/Wo wir KI verwendet haben

- Formulierungshilfen und Prüfung der Rechtschreibung
- Strukturierung
- Brainstorm
- “Feedback“ bzw. Selbstüberprüfung zur Ganzheitlichkeit zum Thema