

SYSTEM CHECK: DIFFUSION

Anisa Chakiri
Daniel Deitschmann

01 // FORWARD PROCESS (Das Prinzip)

Visualisierung:

Skizziere in die Kästchen, wie ein **Smiley** aussieht, wenn wir Gauß-Rauschen hinzufügen.

t=0 (Start)



t=500 (Mitte)



t=1000 (Ende)



Frage:

Muss das neuronale Netz diesen Zerstörungsprozess lernen?

- ☐ Ja, das ist der schwierigste Teil.
- ☐ Nein, das ist ein fester mathematischer Prozess (Zufall).

02 // ARCHITEKTUR (UNet)

Verbinde die Komponenten:

- | | | |
|---------------------|-------|--|
| A. Encoder (Links) | _____ | 1. Baut das Bild wieder auf (Upsampling) |
| B. Skip Connection | _____ | 2. Komprimiert das Bild, versteht den Inhalt |
| C. Decoder (Rechts) | _____ | 3. Kopiert Details vom Encoder zum Decoder |

03 // LATENT SPACE (Stable Diffusion)

Warum rechnet Stable Diffusion im Latent Space (64x64) statt auf Pixeln (512x512)?

Welches Bauteil komprimiert das Bild?

04 // PROMPT ENGINEERING

Situation:

Dein Bild ignoriert deinen Text fast völlig und ist zu "kreativ".

Musst du den **CFG Scale (Guidance)** erhöhen oder senken?

05 // REVERSE CALCULATION (Logik)**Das Prinzip:**

Um das saubere Bild zu bekommen, subtrahiert das Modell das vorhergesagte Rauschen vom aktuellen Bild.

Formel (vereinfacht): $\text{Bild_Neu} = \text{Bild_Aktuell} - \text{Vorhergesagtes_Rauschen}$

Gegeben:

- Pixelwert im verrauschten Bild: **230**
- Das UNet sagt vorher: "Das Rauschen hier ist **50**".

Frage A: Welchen Wert hat das Pixel nach dem Denoising-Schritt?

Frage B: Was passiert mit dem Bild, wenn das UNet das Rauschen falsch vorhersagt (z.B. sagt es 200 statt 50)?

06 // CROSS-ATTENTION MAPS**Szenario:**

Das UNet generiert ein 2x2 Bild (4 Pixel).

Der Prompt ist: "**Roter Mond**".

Hier siehst du die **Attention-Werte** für das Wort "Mond" in den 4 Pixeln. (1.0 = Hohe Aufmerksamkeit, 0.0 = Keine).

0.1	0.9
0.2	0.1

Frage: In welchem Quadranten des Bildes wird der Mond gezeichnet? (Zutreffendes ankreuzen)

- ☐ Oben Links
- ☐ Oben Rechts
- ☐ Unten Rechts